

KLASIFIKASI CITRA DENGAN CNN: DARI AWAL HINGGA TRANSFER LEARNING

DOSEN PENGAMPU : Dr. YASDINUL HUDA, S.Pd., M.T



DISUSUN OLEH :

NAMA : FATIMATUZZAHRO PANE
NIM : 24343007
KODE KELAS : 202523430039

PROGRAM STUDI INFORMATIKA DEPARTEMEN ELEKTRONIKA

FAKULTAS TEKNIK UNIVERSITAS NEGERI PADANG

TAHUN AJARAN 2025/2026

1. Deskripsi Dataset dan Arsitektur CNN

A. Dataset CIFAR-10

Dataset yang digunakan dalam penelitian ini adalah CIFAR-10, yaitu dataset standar dalam bidang Computer Vision yang sering digunakan untuk eksperimen klasifikasi gambar. Dataset ini memiliki karakteristik sebagai berikut:

- Terdiri dari 60.000 gambar berwarna (RGB)
- Resolusi gambar: 32×32 piksel
- Terdiri dari 10 kelas objek
- Distribusi data:
 - 50.000 data training
 - 10.000 data testing

Analisis Dataset

CIFAR-10 termasuk dataset menengah (intermediate difficulty) karena:

- Gambar memiliki resolusi kecil sehingga detail terbatas
- Terdapat objek dengan kemiripan tinggi (contoh: cat vs dog, deer vs horse)
- Background tidak seragam

Hal ini membuat model harus mampu mengekstrak fitur penting secara efektif.

B. Preprocessing Data

a. Normalisasi

- Nilai pixel diubah dari 0–255 menjadi 0–1
- Tujuannya agar proses training lebih stabil

b. One-hot encoding

- Label dikonversi ke bentuk vektor biner
- Contoh: kelas 3 $\rightarrow [0,0,0,1,0,...]$

c. Data subset

- Digunakan sebagian dataset agar training lebih cepat
- Training: 10.000 gambar
- Testing: 2.000 gambar

C. Arsitektur CNN (From Scratch)

Model CNN yang digunakan adalah model dasar dengan struktur:

Conv2D (32 filter, kernel 3×3)	Flatten
MaxPooling2D	Dense output (Softmax 10 kelas)
Conv2D (64 filter)	Dense (256 neuron)
MaxPooling2D	Dropout (0.5)
Conv2D (128 filter)	

Penjelasan Arsitektur:

- Convolution layer berfungsi untuk mengekstrak fitur seperti edge, warna, dan tekstur
- Pooling layer mengurangi dimensi data sehingga komputasi lebih ringan
- Dense layer berfungsi untuk klasifikasi akhir
- Dropout digunakan untuk mencegah overfitting dengan cara menonaktifkan neuron secara acak

D. Analisis CNN from Scratch

Model CNN dari awal memiliki keterbatasan:

- Membutuhkan data besar untuk performa optimal
- Cenderung overfitting pada dataset kecil
- Fitur yang dipelajari masih terbatas

Namun model ini penting sebagai baseline untuk dibandingkan dengan transfer learning.

```
LATIHAN 2: TRANSFER LEARNING DENGAN DATA AUGMENTATION
=====
Training Data : 384
Validation Data : 96
Testing Data : 120
I0000 00:00:1779029205.931649    5312 cpu_feature_guard.cc:227] This TensorFlow binary is optimized to use available CPU instructions in performance-critical
operations.
To enable the following instructions: SSE3 SSE4.1 SSE4.2 AVX AVX2 FMA, in other operations, rebuild TensorFlow with the appropriate compiler flags.

MEMBANGUN MODEL TRANSFER LEARNING...
Downloading data from https://storage.googleapis.com/tensorflow/keras-applications/mobilenet_v2/mobilenet_v2_weights_tf_dim_ordering_tf_kernels_1.0_224_no_top.h5

esc[1m 0/9406464esc[0m esc[37m=====esc[0m esc[1m05esc[0m 0s/step
esc[1m 40960/9406464esc[0m esc[37m=====esc[0m esc[1m125esc[0m 1us/step
esc[1m 49152/9406464esc[0m esc[37m=====esc[0m esc[1m415esc[0m 4us/step
esc[1m 81920/9406464esc[0m esc[37m=====esc[0m esc[1m475esc[0m 5us/step
esc[1m 114688/9406464esc[0m esc[37m=====esc[0m esc[1m385esc[0m 4us/step
esc[1m 147456/9406464esc[0m esc[37m=====esc[0m esc[1m325esc[0m 4us/step
esc[1m 172032/9406464esc[0m esc[37m=====esc[0m esc[1m315esc[0m 3us/step
esc[1m 204800/9406464esc[0m esc[37m=====esc[0m esc[1m285esc[0m 3us/step
esc[1m 245760/9406464esc[0m esc[37m=====esc[0m esc[1m255esc[0m 3us/step
esc[1m 286720/9406464esc[0m esc[37m=====esc[0m esc[1m235esc[0m 3us/step
esc[1m 327680/9406464esc[0m esc[37m=====esc[0m esc[1m225esc[0m 2us/step
esc[1m 335872/9406464esc[0m esc[37m=====esc[0m esc[1m225esc[0m 3us/step
esc[1m 393216/9406464esc[0m esc[37m=====esc[0m esc[1m215esc[0m 2us/step
esc[1m 434176/9406464esc[0m esc[37m=====esc[0m esc[1m205esc[0m 2us/step
esc[1m 483328/9406464esc[0m esc[32m-esc[0mesc[37m=====esc[0m esc[1m195esc[0m 2us/step
esc[1m 557056/9406464esc[0m esc[32m-esc[0mesc[37m=====esc[0m esc[1m175esc[0m 2us/step
esc[1m 598016/9406464esc[0m esc[32m-esc[0mesc[37m=====esc[0m esc[1m165esc[0m 2us/step
```

2. Learning Curve dan Confusion Matrix

A. Learning Curve

Hasil training menunjukkan:

- Accuracy training meningkat secara konsisten
- Validation accuracy lebih rendah dari training accuracy
- Loss training menurun seiring epoch

Analisis

Perbedaan antara training dan validation menunjukkan:

- Adanya overfitting ringan
- Model lebih “menghafal” data training dibanding generalisasi

Data augmentation membantu mengurangi gap ini.

B. Confusion Matrix

Confusion Matrix menunjukkan performa model pada setiap kelas.

Hasil Analisis

- Kelas mudah dikenali:
 - Ship
 - Airplane
 - Truck
- Kelas sering tertukar:
 - Cat vs dog
 - Deer vs horse
 - Bird vs airplane

Penyebab:

- Kemiripan bentuk objek

- Background tidak konsisten
- Resolusi gambar rendah

C. Evaluasi Matrix

Evaluasi menggunakan:

Accuracy	Precision	Recall	F1-Score
----------	-----------	--------	----------

Interpretasi:

- Precision tinggi → prediksi cukup tepat
- Recall bervariasi antar kelas
- F1-score menunjukkan keseimbangan model

3. Visualisasi Feature Maps dan Grad-Cam

A. Feature Maps

Feature maps digunakan untuk melihat bagaimana CNN memproses gambar. Hasil observasi:

- Layer awal mendeteksi;
 - Edge
 - Garis
- Layer tengah mendeteksi:
 - Pola bentuk
- Layer dalam mendeteksi:
 - Representasi objek

Analisis: Semakin dalam layer, fitur semakin abstrak

B. Grad-CAM (Class Activation Mapping)

Grad-CAM digunakan untuk mengetahui bagian gambar yang menjadi fokus model saat melakukan prediksi. Hasil:

- Model fokus pada objek utama gambar
- Namun pada beberapa kasus:
 - Model masih salah fokus ke background

Interpretasi:

Grad-CAM membantu menjelaskan bahwa CNN tidak bekerja seperti “black box”, tetapi memiliki area fokus tertentu.

C. Manfaat Visualisasi

- Membantu interpretasi model
- Mengetahui kesalahan model
- Meningkatkan transparansi AI

use WSL2 or the TensorFlow-DirectML plugin.

Model: "functional_1"

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 150, 150, 3)	0
sequential (Sequential)	(None, 150, 150, 3)	0
true_divide (TrueDivide)	(None, 150, 150, 3)	0
subtract (Subtract)	(None, 150, 150, 3)	0
mobilenetv2_1.00_224 (Functional)	(None, 5, 5, 1280)	2,257,984
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0
dense (Dense)	(None, 128)	163,968
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 1)	129


Total params: 2,422,081 (9.24 MB)
Trainable params: 164,097 (641.00 KB)
Non-trainable params: 2,257,984 (8.61 MB)

4. Tabel Perbandingan Eksperimen

Model	Akurasi	Overfitting	Waktu Training	Kelebihan
CNN From Scratch	±70–75%	Ada	Cepat	Sederhana
CNN + Augmentation	±75–80%	Berkurang	Sedang	Lebih stabil
MobileNetV2	±785–92%	Rendah	Cepat	Paling akurat

Analisis Perbandingan:

- CNN from scratch cocok sebagai baseline
- Augmentation meningkatkan generalisasi
- Transfer learning memberikan hasil terbaik



5. Kesimpulan dan Rekomendasi

A. Kesimpulan

- 1) CNN from scratch mampu melakukan klasifikasi tetapi terbatas
- 2) Data augmentation membantu meningkatkan performa model
- 3) Transfer learning (MobileNetV2) memberikan akurasi tertinggi
- 4) Visualisasi membantu memahami cara kerja model CNN
- 5) Model pre-trained lebih efisien dibanding training dari nol

B. Rekomendasi

- 1) Gunakan transfer learning untuk dataset kompleks
- 2) Gunakan data augmentation untuk mengurangi overfitting
- 3) CNN from scratch cocok untuk pembelajaran dasar
- 4) MobileNetV2 direkomendasikan untuk perangkat dengan resource terbatas
- 5) Gunakan Grad-CAM untuk interpretasi model

6. Lampiran Kode Github

https://github.com/FatimaPane/Pengolahan_Citra_Digital.git